Primer zadatka klasifikacije teksta

U fajlu “Disneyland_reviews_for_class.csv” su dati podaci o komentarima posetilaca Disneyland parkova. Fajl sadrži sledeće kolone (varijable):

- *Review_ID* - jedinstveni identifikator komentara
- *Rating* - ocena koju je posetilac dao parku
- *Year_Month* - godina i mesec posete na koju se komentar odnosi
- Reviewer_Location - država iz koje je autor komentara
- *Review_Test* - tekst komentara
- *Branch* - ogranak Disneyland parka koji je predmet komentara

Koristeći opisane podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Polazeći od kolone *Rating* napraviti novu *sentiment* varijablu sa tri moguće vrednosti (negativan, neutralan, pozitivan) primenjujući sledeće mapiranje:
    - rating 1 i 2 se mapiraju u “negativan” sentiment,
    - rating 3 se mapira u “neutralan” sentiment,
    - rating 4 i 5 se mapiraju u “pozitivan” sentiment

  Varijabla *sentiment* bi trebalo da posluži kao izlazna varijabla za klasifikaciju u ovom zadatku.
- Transformisati kolonu *Review_Text* u numerički oblik primenom Bag of Words modela i konkretno, TF metrike za procenu značajnosti reči. Takođe, proceniti da li bi još neku od varijabli iz polaznog dataset-a trebalo primeniti za kreiranje modela i ako se opredelite da neku / neke varijable uključite, obrazložite ukratko odluku.
- Kreirati prvi klasifikacioni model primenom algoritma Support Vector Machines (SVM), sa linearnim kernelom i podrazumevanim vrednostima hiperparametara.
- Napraviti predikcije primenom kreiranog modela i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa. Interpretirati dobijene vrednosti metrika u kontekstu zadatka.
- Kreirati drugi klasifikacioni model kroz postupak podešavanja hiperparametara. U komentaru navesti koje biste hiperparametre podešavali i na koji način tj koristeći koje opsege / liste vrednosti ako ne biste bili vremenski ograničeni. Zatim, izabrati dva hiperparametra, jedan za transformaciju teksta, drugi za klasifikator, odnosno oba za klasifikator ako hiperparametri nisu primenljivi za transformaciju teksta, i izvršite podešavanje njihovih vrednosti kroz postupak (5-fold) kros-validacije.
- Izvršiti predikcije primenom podešenog modela i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa.
- Uporediti i prokomentarisati rezultate dobijene osnovnim i podešenim modelima.

Primer zadatka klasterizacije teksta

U fajlu “E-Commerce_Reviews_for_class.csv” su dati podaci sa komentarima kupaca jedne online prodavnice o kupljenoj odeći. Fajl sadrži više kolona (varijabli) od kojih su za ovaj zadatak relevantne samo kolone *Title* i *Review Text*.

Koristeći podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Kreirati novu kolonu *review_content* koja objedinjuje sadržaj kolona *Title* i *Review Text* (kroz obično nadovezivanje stringova).
- Transformisati sadržaj kolone *review_content* u vektorsku (tj numeričku) reprezentaciju primenom pristupa zasnovanom na vektorima dokumenata (document vectors), i konkretno vektorskim reprezentacijama koje generiše “all-MiniLM-L12-v2” Sentence Transformers model (model je lokalno dostupan).
- Izvršiti klasterizaciju (transformisanih) novinskih tekstova primenom aglomerativnog hijerarhijskog klasterovanja. Odrediti optimalni broj klastera na osnovu dendrograma i siluet skora (silhouette score). Obrazložiti izbor optimalnog broja klastera.
- Za svaki od klastera odrediti top 10 reči / izraza na osnovu TF-IDF metrike.
- Odrediti veličinu svakog od klastera i opisati svaki klaster na osnovu identifikovanih top 10 reči / izraza, i eventualnog uvida u naslove / sadržaj komentara u okviru klastera.