Blok 1: Klasifikacija teksta i BoW

1. Zadatak za vežbu

Izmeniti funkciju `spacy_preprocessing` tako da iz zadatog teksta (ulazni argument) budu zadržane samo reči koje su imenice, pridevi i glagoli

Kreirati i evaluirati model dobijen sa ovim oblikom selekcije atributa

2. Zadatak za vežbu

Koristeći spaCy, kreirati nove atribute koji predstavljaju:

- Broj imenica
- Broj glagola
- Broj imenovanih entiteta
- Broj znakova interpunkcije

Ispitati koliko su ovi atributi potencijalno značajni za predviđanje izlazne varijable

3. Zadatak za vežbu

Istražiti argumente CountVectoriser konstruktora (tj hiperparametre koje je moguće podešavati) i njihov efekat na performanse klasifikatora:

- Utvrditi (npr. pretragom neta) koji su to argumenti CountVectoriser-a koji se najčešće podešavaju i u kojim opsezima se njihove vrednosti tipično traže
- Uvrstiti neki od identifikovanih značajnih argumenata u postupak finog podešavanja (fine-tuning) pipeline-a rađen na času predavanja i ispitati kako se to odražava na performanse klasifikacije

Blok 2: Klasifikacija teksta i VSM

1. Zadatak za vežbu

Potražiti na internetu koji hiper-parametri VSM / TF-IDF modela su najčešće predmet podešavanja (fine-tuning) i kreirati novi model kroz određivanje optimalne vrednosti za neki od identifikovanih, relevantnih hiper-parametara

Bonus zahtev: razmisliti koja je evaluaciona metrika posebno značajna za primer primene klasifikacije teksta u kontekstu datog zadatka i fine-tuning podesiti da vrši optimizaciju baziranu na toj metrici

2. Zadatak za vežbu

Kreirati novi pipeline koji umesto logističke regresije (LR), koristi stablo odlučivanja kao klasifikator. Uporediti performanse novokreiranog modela sa osnovnim modelom baziranim na LR (tj modelom bez podešenih hiperparam.)

Bonus zahtev: Uraditi podešavanje hiperparam. stabla odlučivanja i uporediti dobijeni model sa podešenim modelom zasnovanim na LR

Blok 3: Klasifikacija teksta i vektori reči

Zadatak za vežbu

Primeniti postupak klasifikacije teksta rađen na času predavanja na zadatak analize sentimenta nad “TripAdvisor Hotel Reviews” dataset-om dostupnim na Kaggle platformi:

https://www.kaggle.com/datasets/thedevastator/tripadvisor-hotel-review-sentiment-analysis

Za zadatak klasifikacije, kreirati izlaznu varijablu na osnovu varijable Rating, tako da vrednosti 1 i 2 predstavljaju negativan sentiment, vrednost 3 odgovara neutralnom sentimentu, dok 4 i 5 odražavaju pozitivan sentiment.

Blok 4: Klasterizacija teksta

Zadatak za vežbu

Fajl *Amazon_Reviews_for_class.csv* sadrži podatke o komentarima proizvoda koji se prodaju preko Amazon platforme. Koristeći varijable koje se odnose na sadržaj komentara (Summary i Text), izvršiti klasterizaciju komentara primenom aglomerativenog hijerarhijskog klasterovanja.

Za vektorsku reprezentaciju komentara koristiti ili vektore reči raspoložive u okviru *spacy* modela ili vektorske reprezentacije teksta koje generiše neki od *sentence transformers* (SBERT) modela.