Blok 1: Klasifikacija teksta i BoW

1. Zadatak za vežbu

Izmeniti funkciju `spacy_preprocessing` tako da iz zadatog teksta (ulazni argument) budu zadržane samo reči koje su imenice, pridevi i glagoli

Kreirati i evaluirati model dobijen sa ovim oblikom selekcije atributa

2. Zadatak za vežbu

Koristeći spaCy, kreirati nove atribute koji predstavljaju:

- Broj imenica
- Broj glagola
- Broj imenovanih entiteta
- Broj znakova interpunkcije

Ispitati koliko su ovi atributi potencijalno značajni za predviđanje izlazne varijable

3. Zadatak za vežbu

Istražiti argumente CountVectoriser konstruktora (tj hiperparametre koje je moguće podešavati) i njihov efekat na performanse klasifikatora:

- Utvrditi (npr. pretragom neta) koji su to argumenti CountVectoriser-a koji se najčešće podešavaju i u kojim opsezima se njihove vrednosti tipično traže
- Uvrstiti neki od identifikovanih značajnih argumenata u postupak finog podešavanja (fine-tuning) pipeline-a rađen na času predavanja i ispitati kako se to odražava na performanse klasifikacije

Blok 2: Klasifikacija teksta i VSM

1. Zadatak za vežbu

Potražiti na internetu koji hiper-parametri VSM / TF-IDF modela su najčešće predmet podešavanja (fine-tuning) i kreirati novi model kroz određivanje optimalne vrednosti za neke od identifikovanih, relevantnih hiper-parametara

Bonus zahtev: razmisliti koja bi evaluaciona metrika mogla biti posebno značajna za klasifikaciju teksta u kontekstu datog zadatka i fine-tuning podesiti da vrši optimizaciju baziranu na toj metrici

2. Zadatak za vežbu

Kreirati novi pipeline koji umesto logističke regresije (LR), koristi stablo odlučivanja kao klasifikator. Uporediti performanse novokreiranog modela sa osnovnim modelom baziranim na LR (tj modelom bez podešenih hiperparam.)

Bonus zahtev: Uraditi podešavanje hiperparam. stabla odlučivanja i uporediti dobijeni model sa podešenim modelom zasnovanim na LR