Blok 1: Klasifikacija teksta i BoW

1. Zadatak za vežbu

Izmeniti funkciju `spacy_preprocessing` tako da iz zadatog teksta (ulazni argument) budu zadržane samo reči koje su imenice, pridevi i glagoli

Kreirati i evaluirati model dobijen sa ovim oblikom selekcije atributa

2. Zadatak za vežbu

Koristeći spaCy, kreirati nove atribute koji predstavljaju:

- Broj imenica
- Broj glagola
- Broj imenovanih entiteta
- Broj znakova interpunkcije

Ispitati koliko su ovi atributi potencijalno značajni za predviđanje izlazne varijable

3. Zadatak za vežbu

Istražiti argumente CountVectoriser konstruktora (tj hiperparametre koje je moguće podešavati) i njihov efekat na performanse klasifikatora:

- Utvrditi (npr. pretragom neta) koji su to argumenti CountVectoriser-a koji se najčešće podešavaju i u kojim opsezima se njihove vrednosti tipično traže
- Uvrstiti neki od identifikovanih značajnih argumenata u postupak finog podešavanja (fine-tuning) pipeline-a rađen na času predavanja i ispitati kako se to odražava na performanse klasifikacije

Blok 2: Klasifikacija teksta i VSM

1. Zadatak za vežbu

Potražiti na internetu koji hiper-parametri VSM / TF-IDF modela su najčešće predmet podešavanja (fine-tuning) i kreirati novi model kroz određivanje optimalne vrednosti za neki od identifikovanih, relevantnih hiper-parametara

Bonus zahtev: razmisliti koja je evaluaciona metrika posebno značajna za primer primene klasifikacije teksta u kontekstu datog zadatka i fine-tuning podesiti da vrši optimizaciju baziranu na toj metrici

2. Zadatak za vežbu

Kreirati novi pipeline koji umesto logističke regresije (LR), koristi stablo odlučivanja kao klasifikator. Uporediti performanse novokreiranog modela sa osnovnim modelom baziranim na LR (tj modelom bez podešenih hiperparam.)

Bonus zahtev: Uraditi podešavanje hiperparam. stabla odlučivanja i uporediti dobijeni model sa podešenim modelom zasnovanim na LR

Blok 3: Klasifikacija teksta i vektori reči

Zadatak za vežbu

Primeniti postupak klasifikacije teksta rađen na času predavanja na zadatak analize sentimenta nad “TripAdvisor Hotel Reviews” dataset-om dostupnim na Kaggle platformi:

https://www.kaggle.com/datasets/thedevastator/tripadvisor-hotel-review-sentiment-analysis

Za zadatak klasifikacije, kreirati izlaznu varijablu na osnovu varijable Rating, tako da vrednosti 1 i 2 predstavljaju negativan sentiment, vrednost 3 odgovara neutralnom sentimentu, dok 4 i 5 odražavaju pozitivan sentiment.

Blok 4: Klasterizacija teksta

Zadatak za vežbu

Fajl *Amazon_Reviews_for_class.csv* sadrži podatke o komentarima proizvoda koji se prodaju preko Amazon platforme. Koristeći varijable koje se odnose na sadržaj komentara (Summary i Text), izvršiti klasterizaciju komentara primenom aglomerativenog hijerarhijskog klasterovanja.

Za vektorsku reprezentaciju komentara koristiti ili vektore reči raspoložive u okviru *spacy* modela ili vektorske reprezentacije teksta koje generiše neki od *sentence transformers* (SBERT) modela.

Blok 6: LangChain Intro

Zadatak 1: Sekvencijalni lanac za pregled i poboljšanje koda

Kreirati sekvencijalni lanac koji kao ulaz prima segment Python koda i izvršava (sekvencijalno) sledeća dva zadatka:

1) Proverava ispravnost koda (sintaksne greške), kao i njegovu čitljivost i efikasnost
2) Na osnovu uvida ostvarenih u prvom koraku, generiše poboljšanu (refaktorisanu) verziju koda

Primer ulaza:

```
def get_big_nums(nums):
    res = []
    for x in nums:
        if x > 100:

res.append(x)
    return res
```

Izlaz prvog koraka (lanca): string koji sadrži detaljan pregled problema; npr., "Naziv funkcije je zbunjujući; petlja je neefikasna, trebalo bi koristiti list comprehension."

Izlaz drugog koraka (lanca): string koji sadrži korigovan kod

Zadatak 2: Sekvencijalni lanac za generisanje plana učenja

Kreirati sekvencijalni lanac koji kao ulaz prima cilj učenja za narednu nedelju (oblast koju treba savladati u tom periodu) i broj sati za učenje tokom nedelje. Lanac pravi plan učenja kroz sledeća dva (sekvencijalna) koraka:

1) Kreiranje osnovnog plana učenja zadate oblasti u toku jedne nedelje; osnovni plan sadrži listu aktivnosti učenja
2) Preciziranje polaznog plana učenja, na osnovu zadatog broja sati raspoloživog za učenje tokom jedne nedelje (dat npr., kao lista od 7 brojeva)

Izlaz prvog koraka (lanca): lista aktivnosti učenja (npr. [“Upoznavanje sa LangChain API-em”, “Upoznavanje sa osnovnim konceptima i pisanje jednostavnih lanaca”,...]).

Izlaz drugog koraka (lanca): rečnik koji za svaki radni dan u nedelji sadrži listu aktvnosti koje treba kompletirati (npr., {“Ponedeljak”: [...], “Utorak”:[...], ... ,“Petak”:[...]})

Blok 7: Zero & Few Shot Learning

Zadatak za vežbu

Primeniti postupak *zero shot* ili *few shot learning*-a rađen na času predavanja na zadatak klasifikacije sentimenta, koristeći podatke iz “TripAdvisor Hotel Reviews” dataset-a dostupne na Kaggle-u:

https://www.kaggle.com/datasets/thedevastator/tripadvisor-hotel-review-sentiment-analysis

Za potrebe klasifikacije, kreirati izlaznu varijablu na osnovu varijable *Rating*, tako da vrednosti 1 i 2 predstavljaju negativan sentiment, vrednost 3 odgovara neutralnom sentimentu, dok 4 i 5 odražavaju pozitivan sentiment.